FACULTAD DE MEDICINA
UNIVERSIDAD DE CHILE

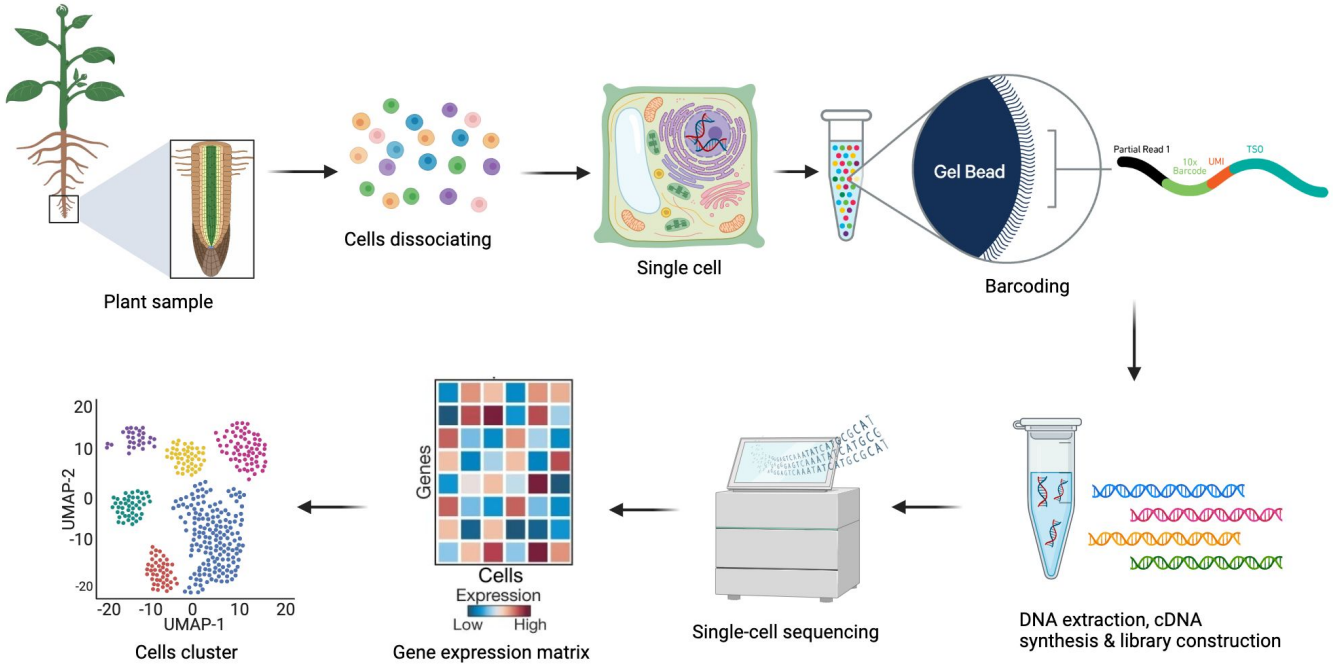
Magíster en Informática Médica

Single-cell RNA-seq II

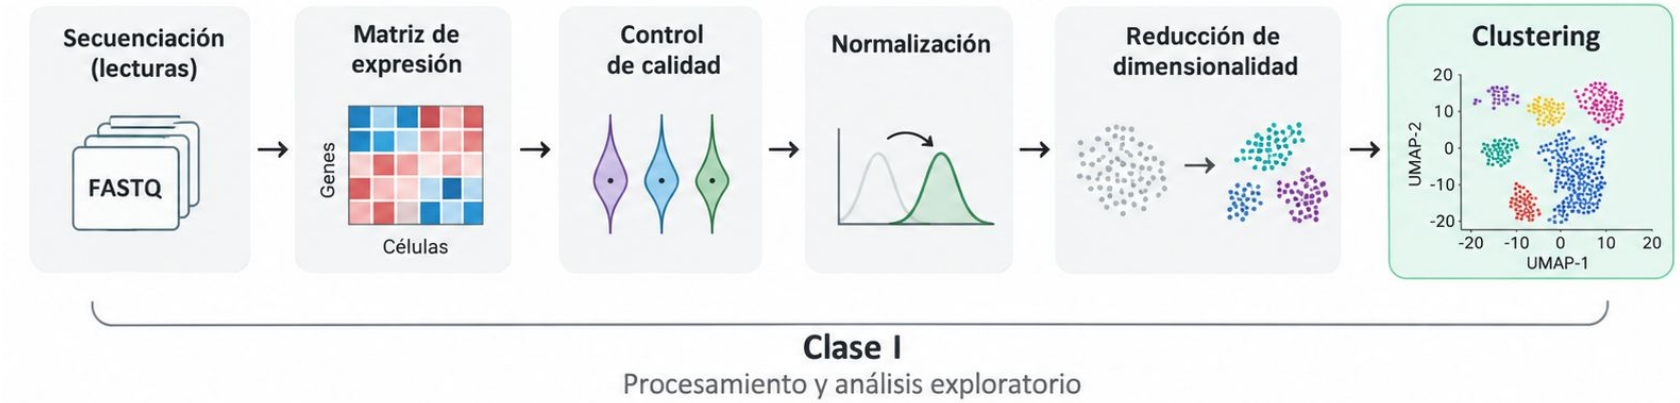
Noemí Gómez
07 de noviembre, 2026

noemi.gomez@postgrado.uoh.cl

Single-cell RNA-seq

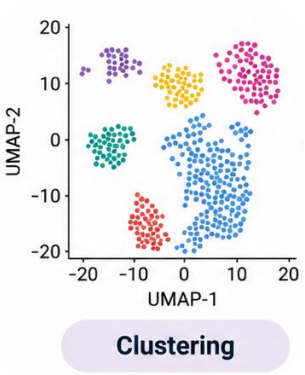


Recapitulación…



Tenemos los clusters… ¿ahora qué?

¿Qué podemos analizar con scRNA-seq?



1 Genes marcadores

¿Qué distingue a cada clúster?

2 Anotación celular

¿Qué tipos celulares tenemos?

3 Composición celular

¿En qué proporciones están?

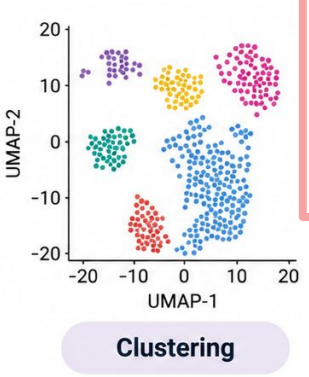
4 Pseudobulk

Agregación por muestra y tipo

5 Expresión diferencial

¿Qué cambia entre condiciones?

¿Qué podemos analizar con scRNA-seq?



1 Genes marcadores

¿Qué distingue a cada clúster?

2 Anotación celular

¿Qué tipos celulares tenemos?

3 Composición celular

¿En qué proporciones están?

4 Pseudobulk

Agregación por muestra y tipo

5 Expresión diferencial

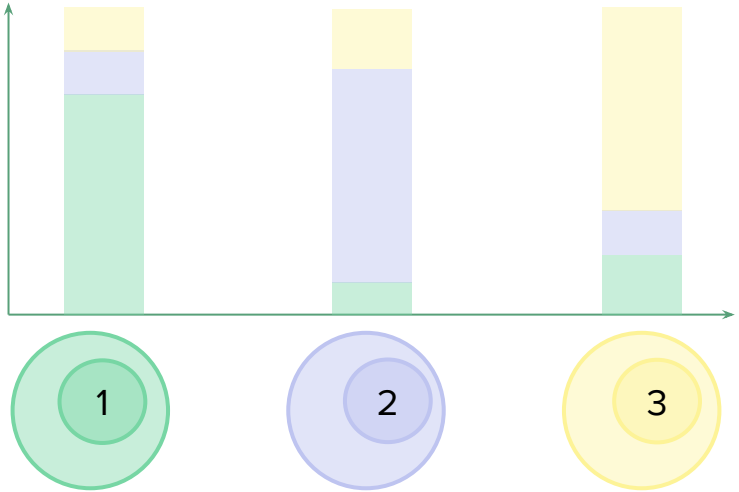
¿Qué cambia entre condiciones?

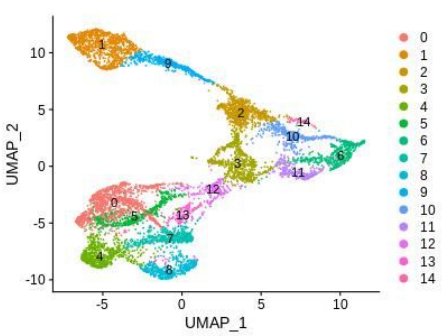
Gen marcador

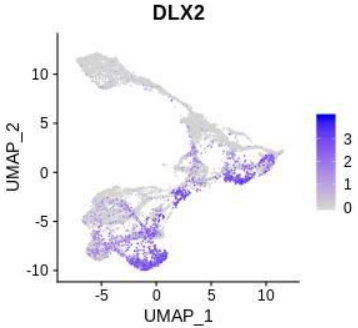
Gen cuya expresión permite caracterizar o distinguir una población celular de otras

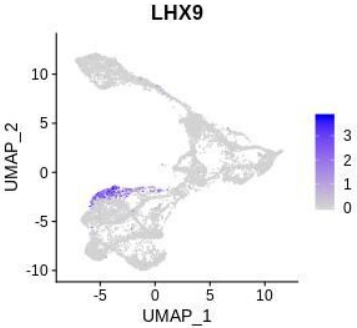
Características

- Expresión enriquecida en una población.
- No necesariamente exclusivo de ese grupo.
- Puede ayudar a reconocer su identidad o estado celular.







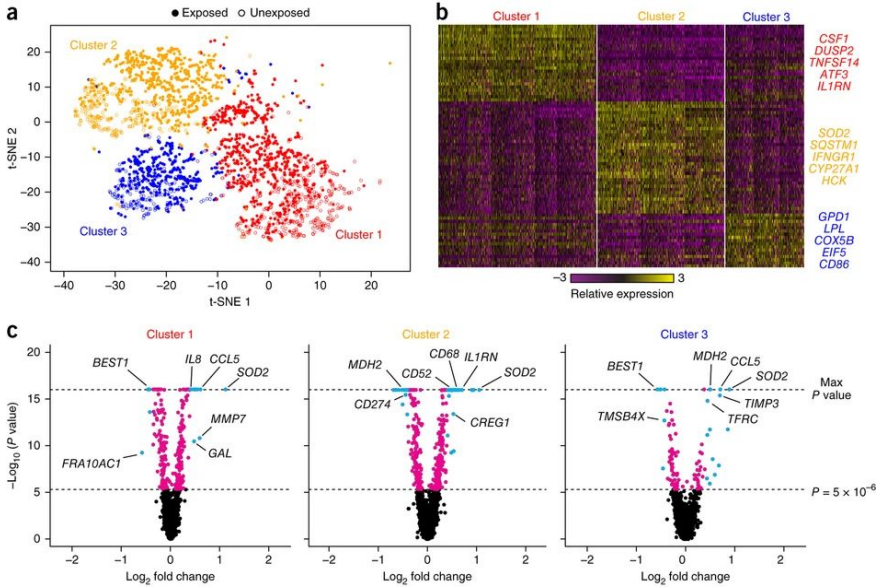


Un gen marcador no tiene que expresarse exclusivamente en un clúster, sino permitir distinguirlo de los demás

¿Cómo identificamos un gen marcador?

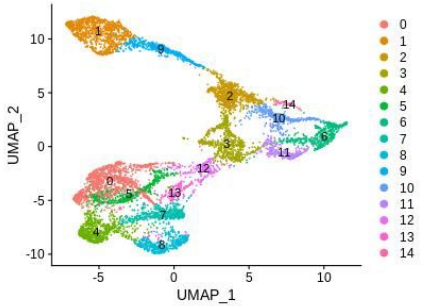
Análisis de expresión diferencial entre las células de un cluster vs el resto

1. Separar las células en 2: cluster a evaluar y el resto
2. Realizar expresión diferencial entre los grupos
3. Identificar genes candidatos de acuerdo a su sobreexpresión en el cluster de interés
4. Repetir para todos los clusters de estudio



Identificación de genes con Seurat

```
library(Seurat)
obj <- NormalizeData(obj)
obj <- FindVariableFeatures(obj, nfeatures = 2000)
obj <- ScaleData(obj)
obj <- RunPCA(obj)
obj <- FindNeighbors(obj, dims = 1:20)
obj <- FindClusters(obj)
obj <- RunUMAP(obj, dims = 1:20)
```




```
# Comparar el cluster seleccionado contra el resto
FindMarkers(obj, ident.1 = "0")
```

```
# Repite automáticamente la comparación de
cada clúster frente al resto
FindAllMarkers(obj, only.pos = TRUE,
               min.pct = 0.25, logfc.threshold = 0.25)
```

Parámetro	**¿Qué controla?**
only.pos	Devuelve únicamente marcadores con cambio positivo de expresión.
min.pct	Evalúa genes detectados en al menos el 25% de las células de uno de los grupos.
logfc.threshold	Filtra genes con diferencias de expresión inferiores al umbral de log2FC indicado.

(*) Test estadístico: por defecto, ambas funciones utilizan Wilcoxon para comparar la expresión de cada gen entre grupos celulares

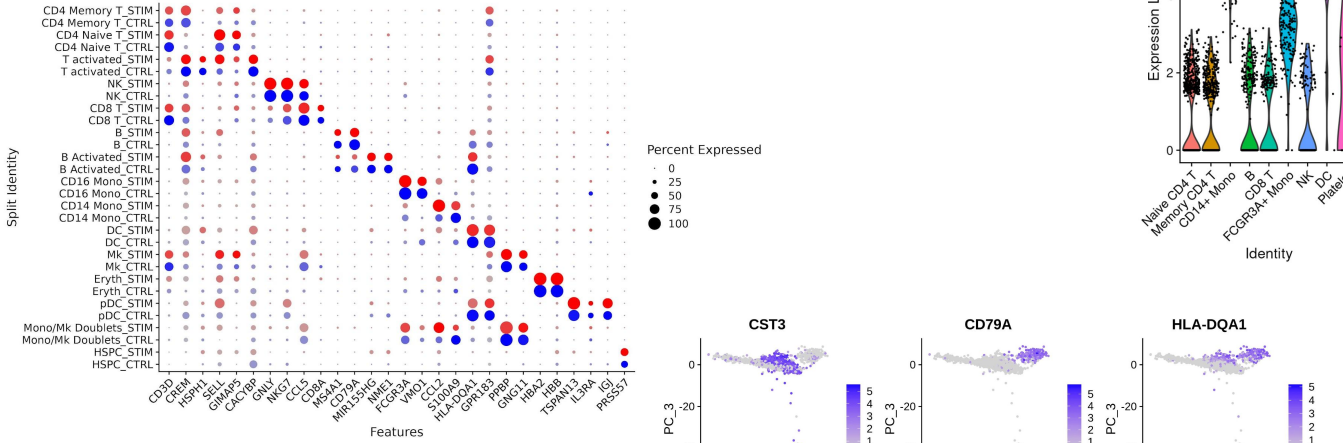
Los resultados son los de una expresión diferencial

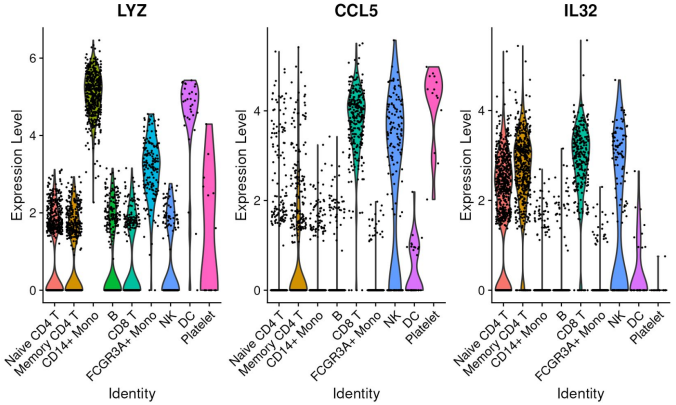
FindAllMarkers() → Tabla de genes marcadores candidatos para cada cluster

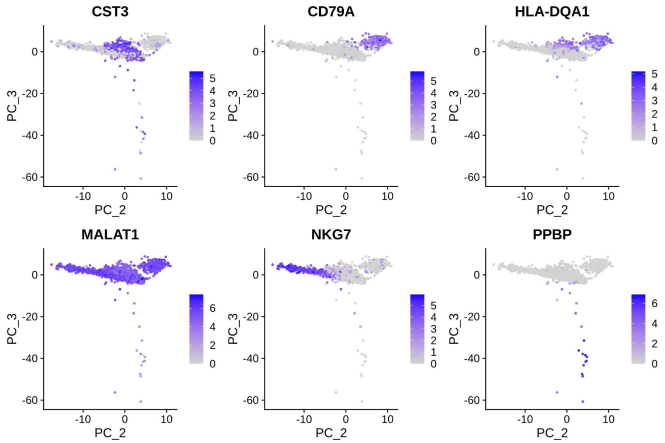
Gene	Cluster	avg_log2FC	pct.1	pct.2	p_val_adj
Gen 1	0	3.85	0.88	0.21	2.1e-08
Gen 2	1	-2.42	0.79	0.18	3.5e-06
Gen 3	*2*	*2.13*	*0.91*	*0.09*	*1.2e-1*

- avg_log2FC: indica cuánto cambia la expresión promedio de un gen entre el clúster de interés y el resto.
- pct.1 y pct.2: proporción de células que expresan el gen el cluster de interés (1) y en el resto (2).

Seurat permite realizar la visualización







Pongámoslo a prueba

Práctico Parte I: Obtener genes marcadores candidatos.

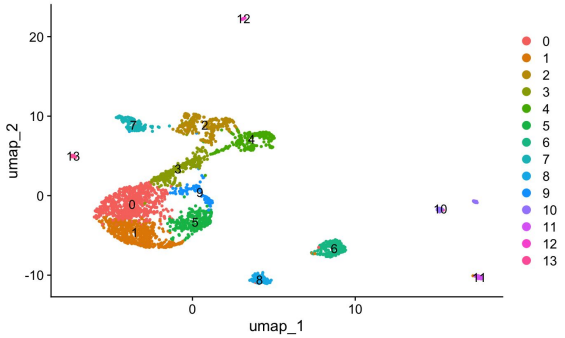
- Cargar el objeto seurat del práctico de la clase 1.
- Estimar los marcadores con FindAllMarkers()
- Extraer el top 3 genes candidatos de cada cluster y visualizar mediante DotPlot, FeaturePlot, VlnPlot y DoHeatmap

https://github.com/noemigomezr/scRNAseq_MIM/

```
library(SingleCellExperiment)
library(Seurat)
library(tidyverse)

load("../output/clase1_clustering.RData")
table(Idents(obj))
DimPlot(obj, reduction = “umap”, label = TRUE)
```

sce	S4 [27998 x 3000] (SingleCell	S4 object of class SingleCellExperiment
int_elementMetadata	S4 [27998 x 1] (S4Vectors::DF	S4 object of class DFrame
int_colData	S4 [3000 x 3] (S4Vectors::DFr	S4 object of class DFrame
int_metadata	list [1]	List of length 1
rowRanges	S4 (GenomicRanges::Compres	S4 object of class CompressedGRangesList
colData	S4 [3000 x 4] (S4Vectors::DFr	S4 object of class DFrame
assays	S4 [27998 x 3000] (Summariz	S4 object of class SimpleAssays
NAMES	NULL	Pairlist of length 0
elementMetadata	S4 [27998 x 0] (S4Vectors::DF	S4 object of class DFrame
metadata	list [0]	List of length 0



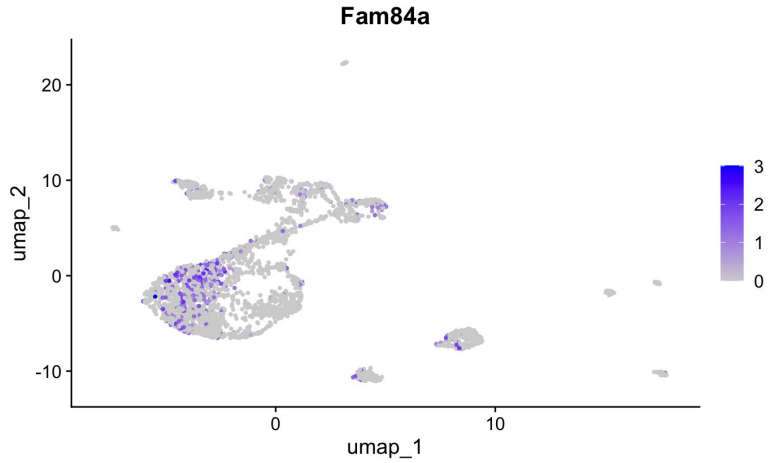
0	1	2	3	4	5	6	7	8	9	10	11	12	13
648	539	284	258	244	234	198	148	118	105	52	44	21	18

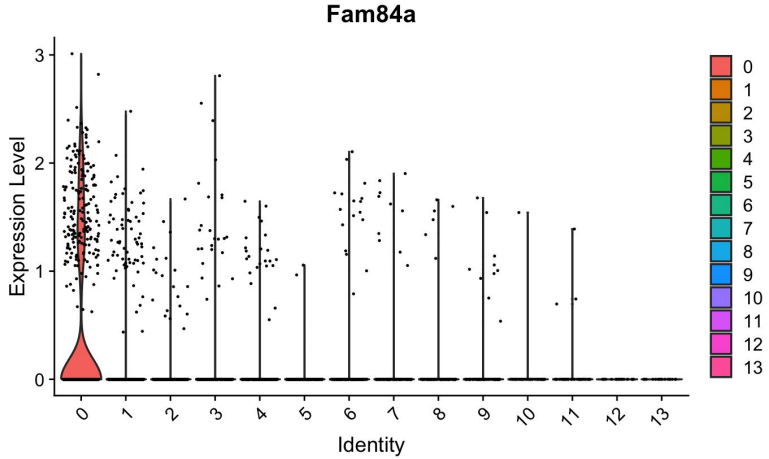
obj	S4 [27998 x 2911] (SeuratObj	S4 object of class Seurat
assays	list [1]	List of length 1
meta.data	list [2911 x 7] (S3: data.frame	A data.frame with 2911 rows and 7 columns
active.assay	character [1]	'RNA'
active.ident	factor	Factor with 14 levels: "0", "1", "2", "3", "4", "5", ...
graphs	list [2]	List of length 2
neighbors	list [0]	List of length 0
reductions	list [7]	List of length 7
images	list [0]	List of length 0
project.name	character [1]	'Brain_E18'
misc	list [0]	List of length 0
version	list [1] (S3: package_version,	List of length 1
commands	list [8]	List of length 8
tools	list [0]	List of length 0

```
# Comparar el clúster 0 con el resto
markers_0 <- FindMarkers(obj, ident.1 = "0",
                         only.pos = TRUE, min.pct = 0.25,
                         logfc.threshold = 0.25)

markers_0_fdr <- subset(markers_0, subset = p_val_adj < 0.05 & avg_log2FC > 1)
markers_0_fdr %>% arrange(desc(avg_log2FC)) %>% slice_head(n=1)
FeaturePlot(obj, features = "Fam84a", reduction = "umap")
VlnPlot(obj, features = "Fam84a", pt.size = 0.1)
```

	p_val	avg_log2FC	pct.1	pct.2	p_val_adj
Fam84a	1.789144e-50	2.36935	0.298	0.082	5.009247e-46





```
markers <- FindAllMarkers(obj, only.pos = TRUE,
                          min.pct = 0.25,logfc.threshold = 0.25)
# cuantos marcadores se identificaron por cluster
markers %>% filter(p_val_adj < 0.05) %>% count(cluster, name = "n_markers")
```

	cluster	n_markers
1	0	201
2	1	412
3	2	1263
4	3	336
5	4	709
6	5	542
7	6	113
8	7	100
9	8	65
10	9	173
11	10	1095
12	11	421
13	12	433
14	13	16

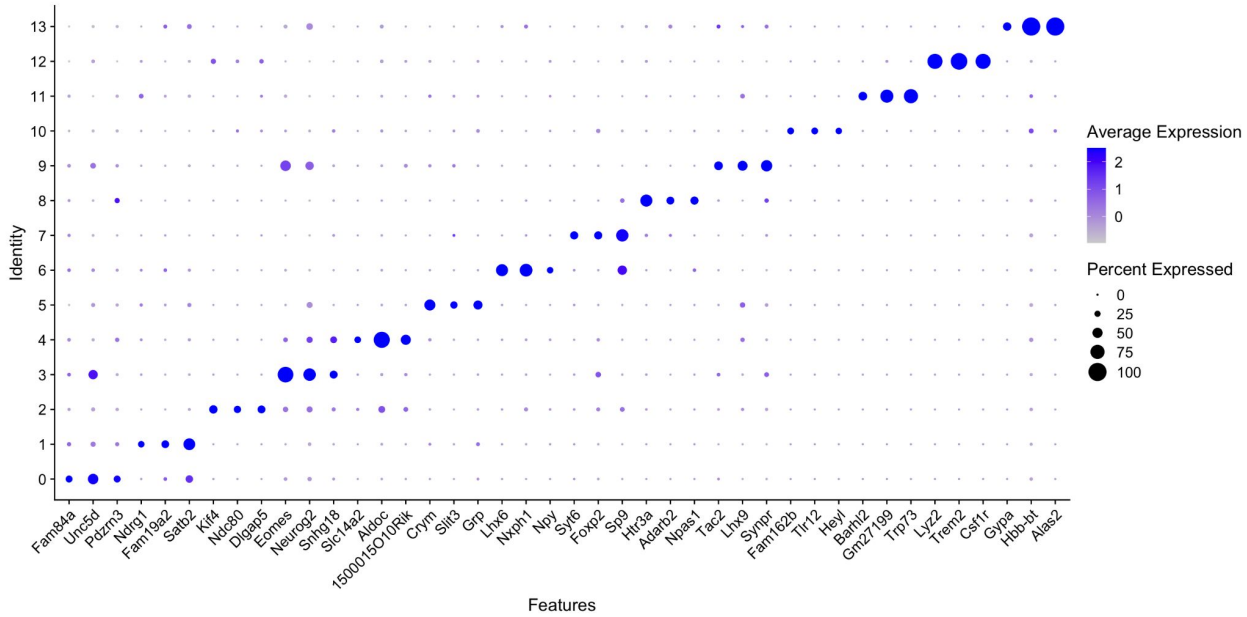
```
# Seleccionar marcadores candidatos
markers_sig <- markers %>% filter(p_val_adj < 0.05, pct.1 > pct.2)

# Seleccionar los 3 genes con mayor log2FC por clúster
top3 <- markers_sig %>% group_by(cluster) %>%
  slice_max(order_by = avg_log2FC, n = 3, with_ties = FALSE) %>% ungroup()

top3 %>% select(cluster, gene, avg_log2FC, pct.1, pct.2, p_val_adj)
genes_plot <- unique(top3$gene)
```

```
# A tibble: 42 × 6
   cluster gene    avg_log2FC pct.1 pct.2 p_val_adj
   <fct>   <chr>        <dbl> <dbl> <dbl>     <dbl>
 1 0       Fam84a        2.37 0.298 0.082 5.01e- 46
 2 0       Unc5d         2.30 0.52  0.154 1.09e- 91
 3 0       Pdzrn3        2.25 0.296 0.088 6.24e- 42
 4 1       Ndrg1         3.99 0.271 0.026 1.50e- 85
 5 1       Fam19a2       3.09 0.349 0.043 9.17e- 97
 6 1       Satb2         2.57 0.599 0.128 5.47e-129
 7 2       Kif4          6.80 0.387 0.005 3.28e-201
 8 2       Ndc80         6.75 0.32  0.003 1.69e-166
 9 2       Dlgap5        6.47 0.356 0.004 1.72e-185
10 3       Eomes         4.19 0.845 0.089 5.20e-241
```

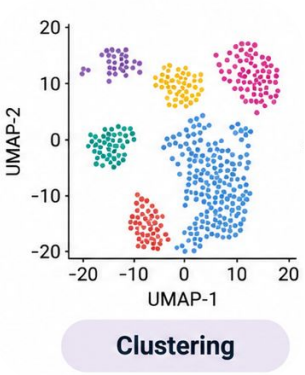
```
DotPlot(obj, features = genes_plot) + RotatedAxis()
```



```
obj_heatmap <- ScaleData(obj, features = genes_plot, verbose = FALSE)
DoHeatmap(obj_heatmap, features = genes_plot) + NoLegend()
```

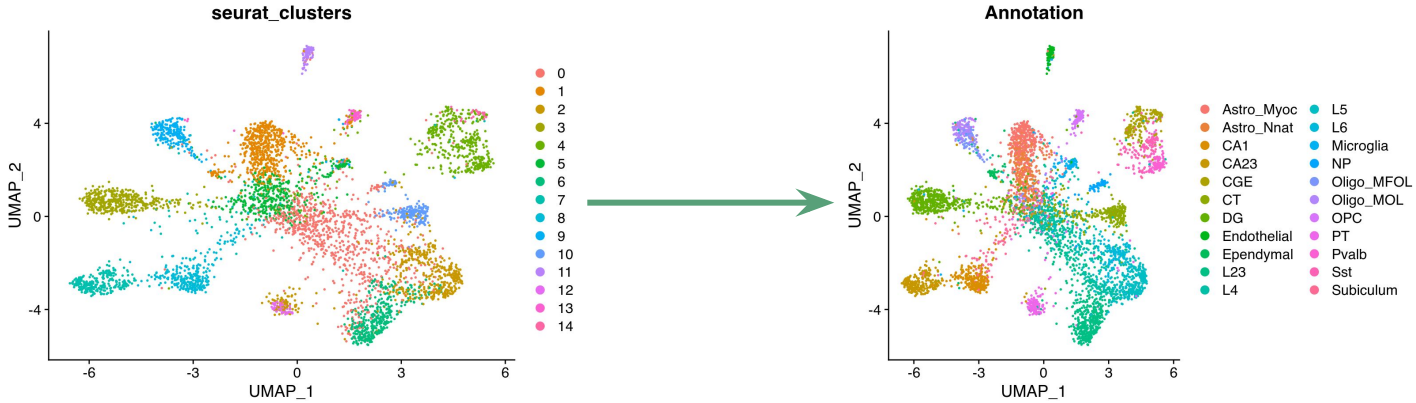


¿Qué podemos analizar con scRNA-seq?





De clustering a la identidad celular



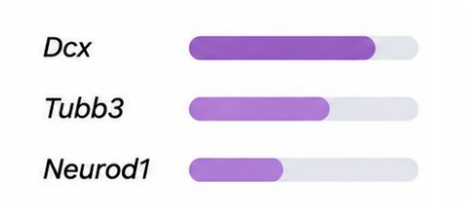
- Clúster: Grupo de células con perfiles transcriptómicos similares, definido computacionalmente.
- Tipo celular: Población con una identidad biológica reconocible, asociada a características moleculares y funcionales.
- Estado celular: Condición funcional o transitoria de una célula, como proliferación, activación o diferenciación.

Un clúster no equivale necesariamente a un tipo celular: puede reflejar distintos tipos, subtipos o estados celulares.

Los genes marcadores ayudan a reconocer el tipo celular

1

Marcadores de cluster
Obtenidos con Seurat FindAllMarkers()



2

Asignación de genes con conocimiento biológico
Bases de datos de genes marcadores de células específicas



3

Identidad propuesta
Se asigna una identidad de acuerdo al patrón observado



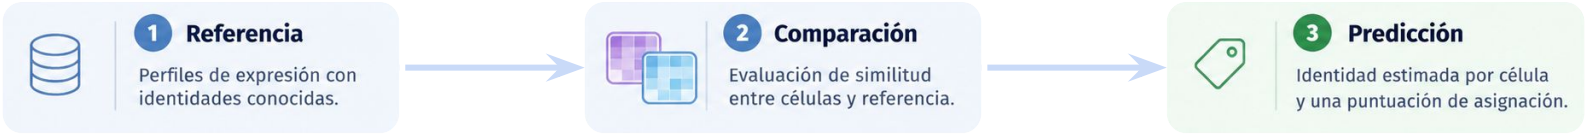
Neurona inmadura

¿Son genes marcadores conocidos? ¿Se expresan de forma conjunta? ¿Es coherente con el tejido?

```
obj <- RenameIdents(obj, “2” = “Neurona inmadura”)
obj$cell_type <- as.character(Idents(obj))
```

La identidad celular se propone a partir de la combinación de marcadores y su concordancia con referencias biológicas

Automatización de la anotación celular



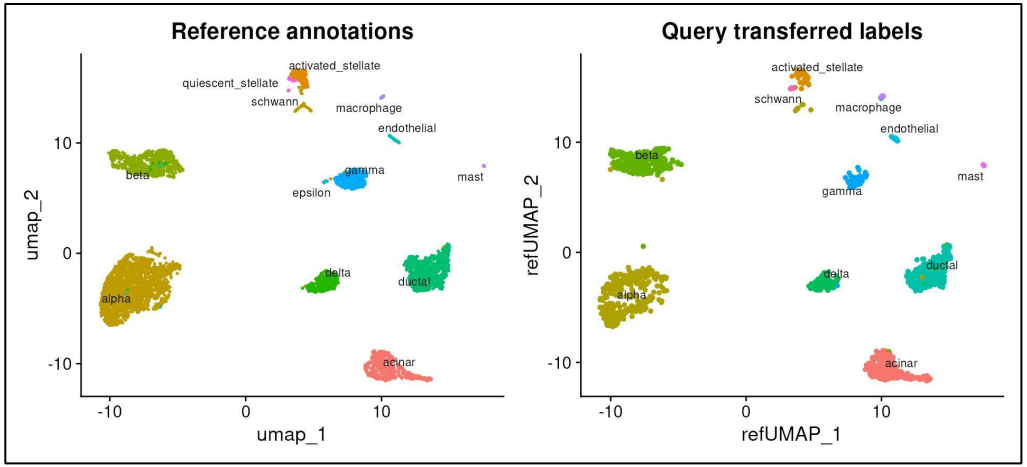
	Single R	Seurat
Método	Correlación y comparación entre perfiles de expresión	Identificación de correspondencias entre células *(anchors)*
Funciones principales	*SingleR()*	*FindTransferAnchors()* ⟶ *TransferData()*
Referencia requerida	Matriz de expresión y etiquetas conocidas	Objeto Seurat previamente anotado
Resultado	Etiqueta predicha y puntuaciones de similitud	Etiqueta predicha y puntuaciones

Anotación celular con Seurat

```
# 1. Buscar correspondencias
anchors <- FindTransferAnchors(reference = referencia,  query = obj, dims = 1:20)

# 2. Transferir identidades
pred <- TransferData(anchorset = anchors,  refdata = referencia$cell_type, dims = 1:20)

# 3. Guardar y visualizar
obj <- AddMetaData(obj, metadata = pred)
DimPlot(obj, reduction = "umap", group.by = "predicted.id")
```



Las poblaciones esperadas dependen del tejido, su origen y contexto biológico de la muestra

Tejido y región

Cerebro, sangre, tumor, etc.

Etapa biológica

Desarrollo, maduración o envejecimiento.

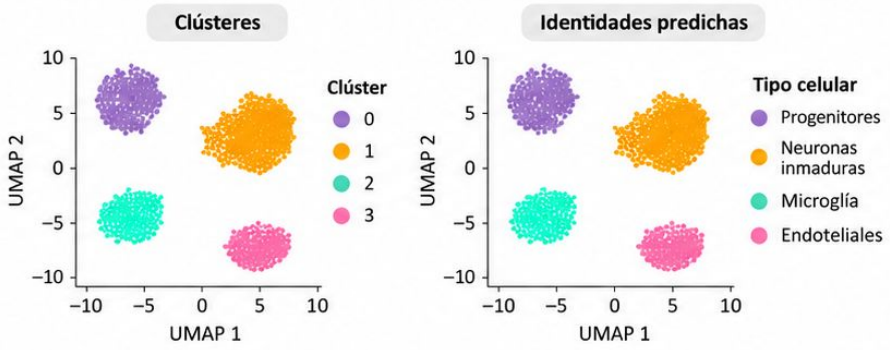
Condición biológica

Estado fisiológico o patológico.

Evaluación de la anotación

1 Concordancia entre células y clústeres

¿Las células agrupadas presentan identidades predichas consistentes?

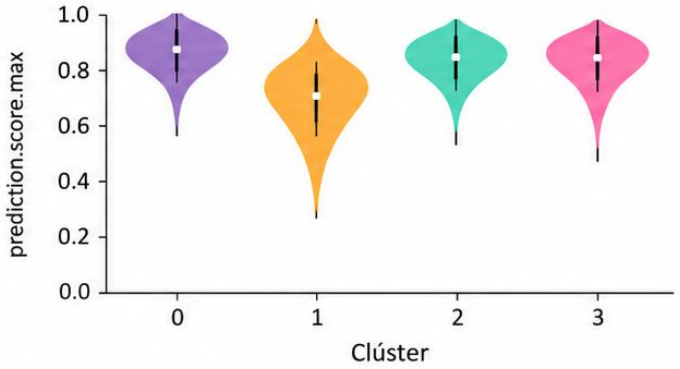


Concordancia: la mayoría de las células de un clúster comparten la misma identidad.

Revisión: un clúster con identidades heterogéneas puede requerir revisión.

2 Confianza de las predicciones

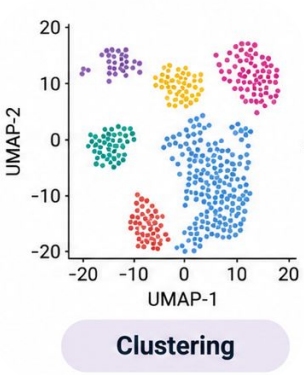
¿Qué tan respaldada está la identidad asignada a cada célula?



Puntuaciones altas: mayor respaldo de la identidad asignada.

Puntuaciones bajas: asignación menos definida.

¿Qué podemos analizar con scRNA-seq?



1 Genes marcadores

¿Qué distingue a cada clúster?

2 Anotación celular

¿Qué tipos celulares tenemos?

3 Composición celular

¿En qué proporciones están?

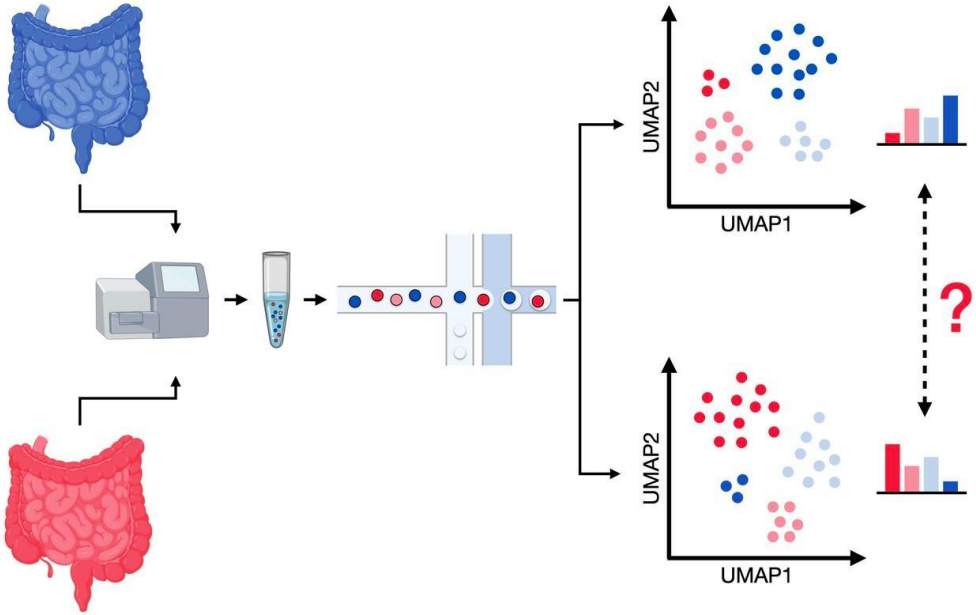
4 Pseudobulk

Agregación por muestra y tipo

5 Expresión diferencial

¿Qué cambia entre condiciones?

¿Qué es la composición celular?

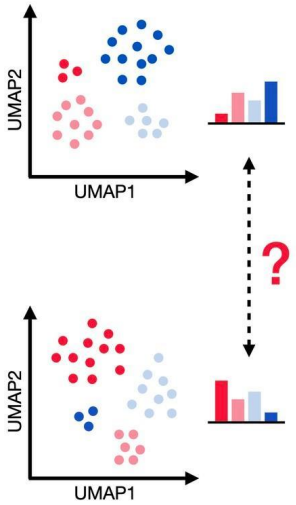


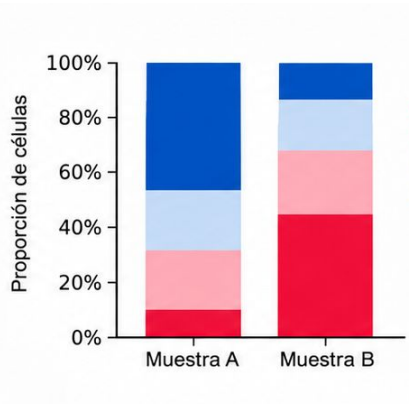
Describe la distribución relativa de los distintos tipos celulares identificados

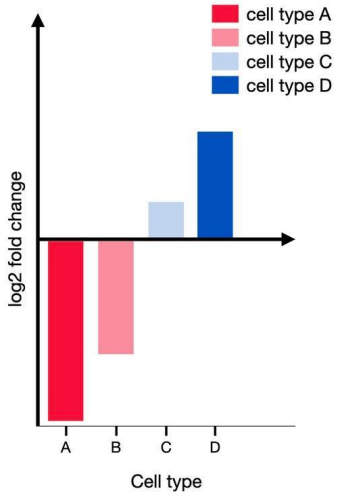
Las diferencias biológicas no siempre se manifiestan en cambios de expresión, sino en la distribución de poblaciones celulares

Nos permite describir y comparar la representación de diferentes poblaciones, pero es una diferencia *relativa*

Cuantificación de la composición celular







Conteo

Número de células de cada tipo en cada muestra.

Proporción

$$\textit{Proporción} = \frac{\text{células de un tipo}}{\text{total de células de la muestra}} \times 100$$

Comparación

Las proporciones permiten comparar la composición entre muestras o condiciones.

Pongámoslo a prueba… otra vez

Práctico Parte II: A partir de donde quedamos con la anotación

- Cargar referencia de tipos de células de cerebro de ratón.
- Realizar anotación celular.
- Evaluar la anotación, ¿qué clusters están mejor definidos?
- ¿Cuál es la célula más presente?
- Comparar la composición celular entre ratón A y B.

```
BiocManager::install("scRNAseq", update = FALSE, ask = FALSE)
library(scRNAseq)

# Referencia de mesencéfalo embrionario de ratón
sce_ref <- LaMannoBrainData("mouse-embryo", ensembl = FALSE, location = FALSE)
sce_ref <- sce_ref[, !is.na(sce_ref$Cell_type)]
rownames(sce_ref) <- make.unique(rownames(sce_ref))

referencia <- CreateSeuratObject(counts = as(assay(sce_ref, "counts"), "dgCMatrix"),
                                 project = "LaManno")
referencia$cell_type <- as.character(sce_ref$Cell_type)
table(referencia$cell_type)
```

Etiqueta	Identidad original	Explicación breve
mNbM	Neuroblastos mediales	Células neuronales inmaduras de la región medial del mesencéfalo.
mNbML2	Neuroblastos mediolaterales, subtipo 2	Población de neuroblastos en diferenciación; en la referencia se relaciona con linajes GABAérgicos.
mNbL2	Neuroblastos laterales, subtipo 2	Células neuronales inmaduras de regiones laterales.
mNbDA	Neuroblastos dopaminérgicos	Precursores neuronales asociados con el linaje dopaminérgico.
mNProg	Progenitores neuronales	Células precursoras que participan en la generación de neuronas.
mRgl1	Glía radial, subtipo 1	Población de glía radial con características progenitoras.
mRgl2	Glía radial, subtipo 2	Subpoblación de glía radial con un perfil transcriptómico diferente de Rgl1.
mEpen	Células ependimarias	Células del linaje ependimario asociado a las cavidades ventriculares.
mMgl	Microglía	Células inmunitarias residentes del sistema nervioso central.
mEndo	Células endoteliales	Células que forman el revestimiento interno de los vasos sanguíneos.
mPeric	Pericitos	Células asociadas a los vasos que contribuyen a su estructura y regulación.
mUnk	Identidad desconocida	Células cuya identidad no está definida por la anotación de referencia.

```
# referencia se prepara igual que un estudio de single cell
referencia <- NormalizeData(referencia, verbose = FALSE)
referencia <- FindVariableFeatures(referencia, verbose = FALSE)
referencia <- ScaleData(referencia, verbose = FALSE)
referencia <- RunPCA(referencia, npcs = 30, verbose = FALSE)
```

```
DefaultAssay(obj) <- "RNA"
Idents(obj) <- "seurat_clusters"
length(intersect(rownames(obj), rownames(referencia)))

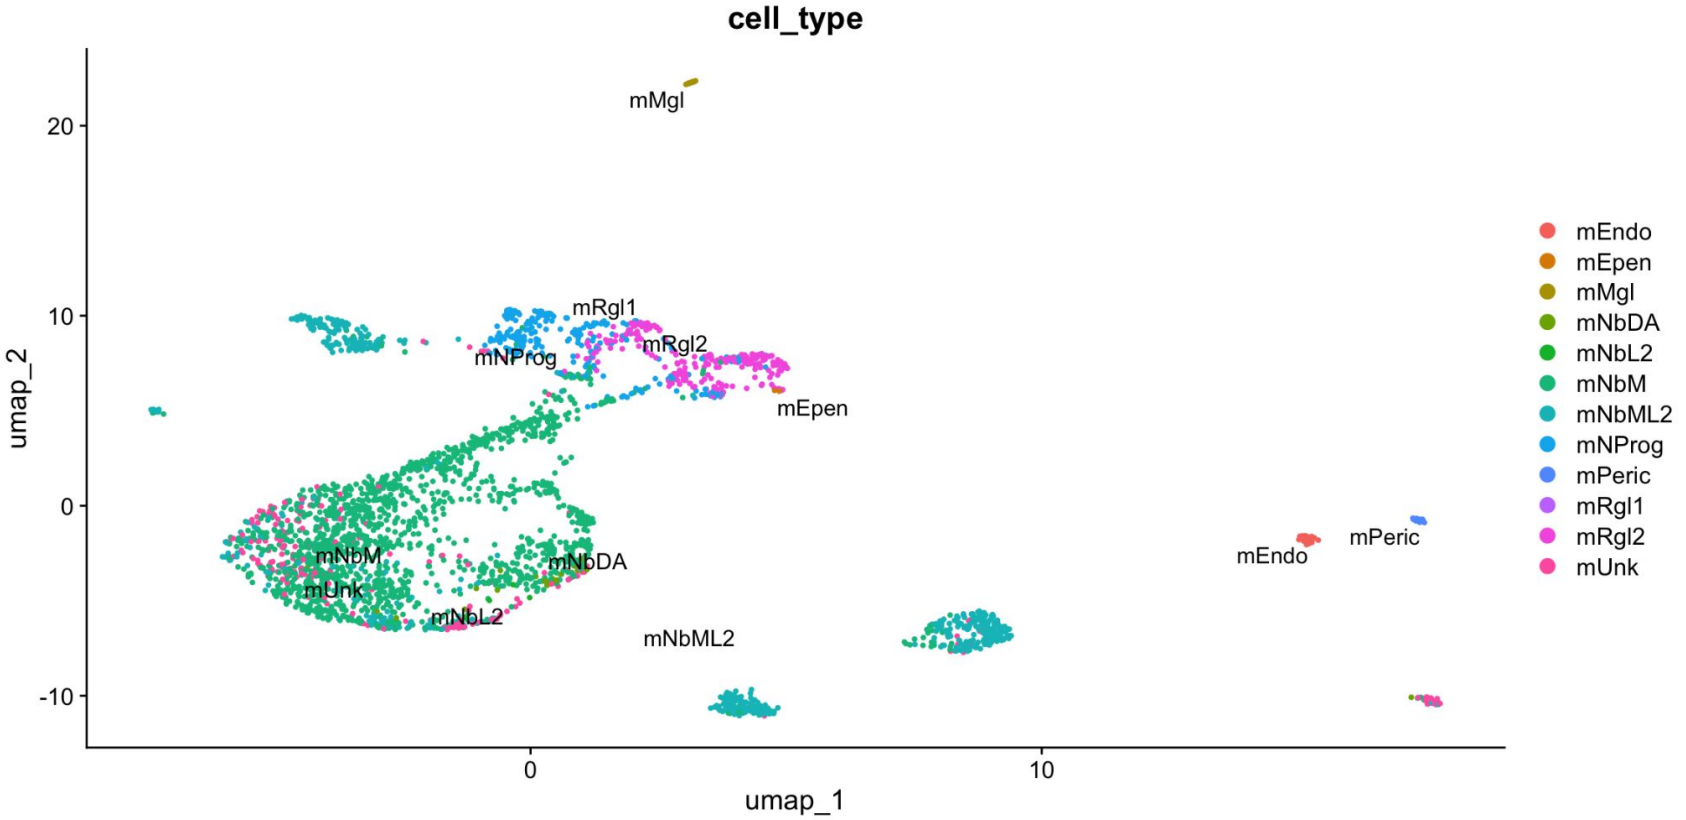
anchors <- FindTransferAnchors(reference = referencia, query = obj,
                               reference.reduction = "pca", dims = 1:20)
```

```
[1] 20644


Projecting cell embeddings
Finding neighborhoods
Finding anchors
       Found 1099 anchors
```

```
pred <- TransferData(anchorset = anchors,
                     refdata = referencia$cell_type, dims = 1:20)
obj <- AddMetaData(obj, metadata = pred)
obj$cell_type <- obj$predicted.id
```

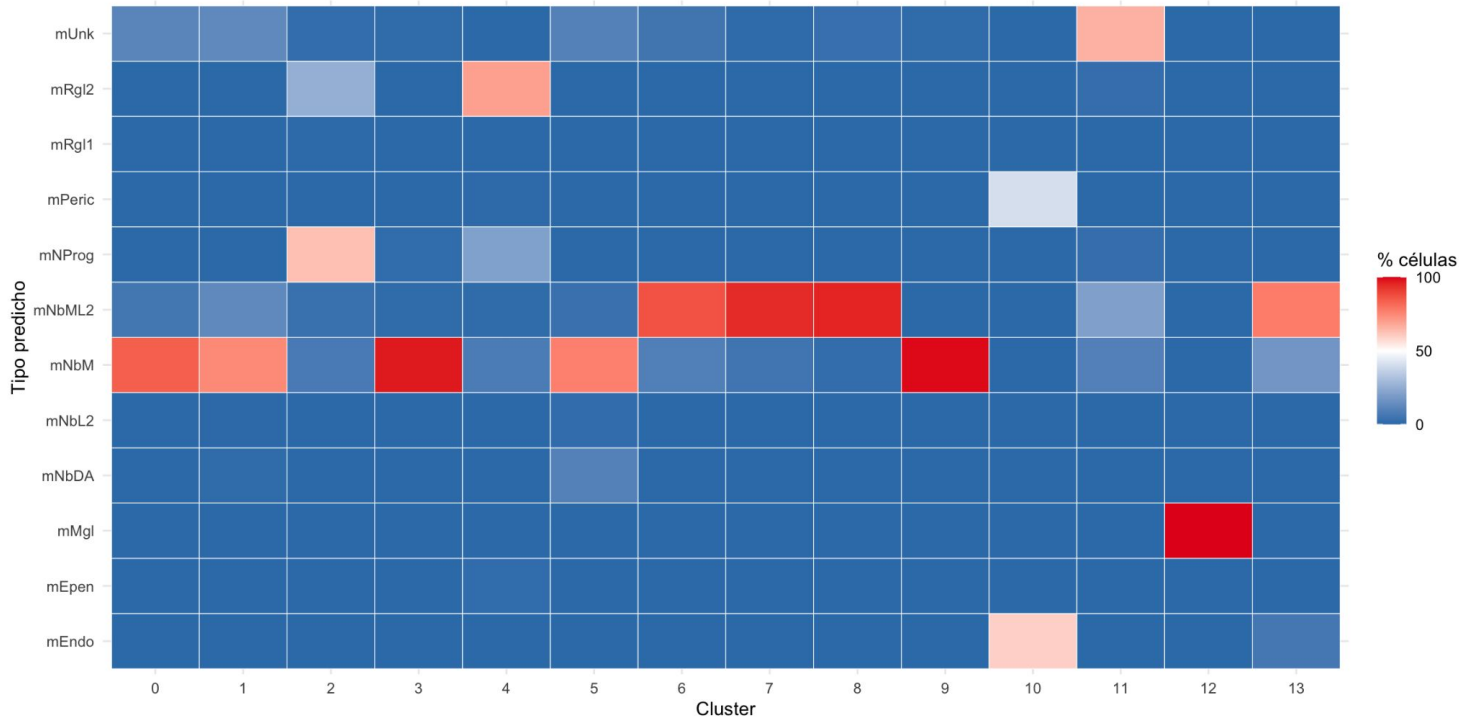
```
DimPlot(obj, reduction = "umap", group.by = "cell_type", label = TRUE, repel = TRUE)
```



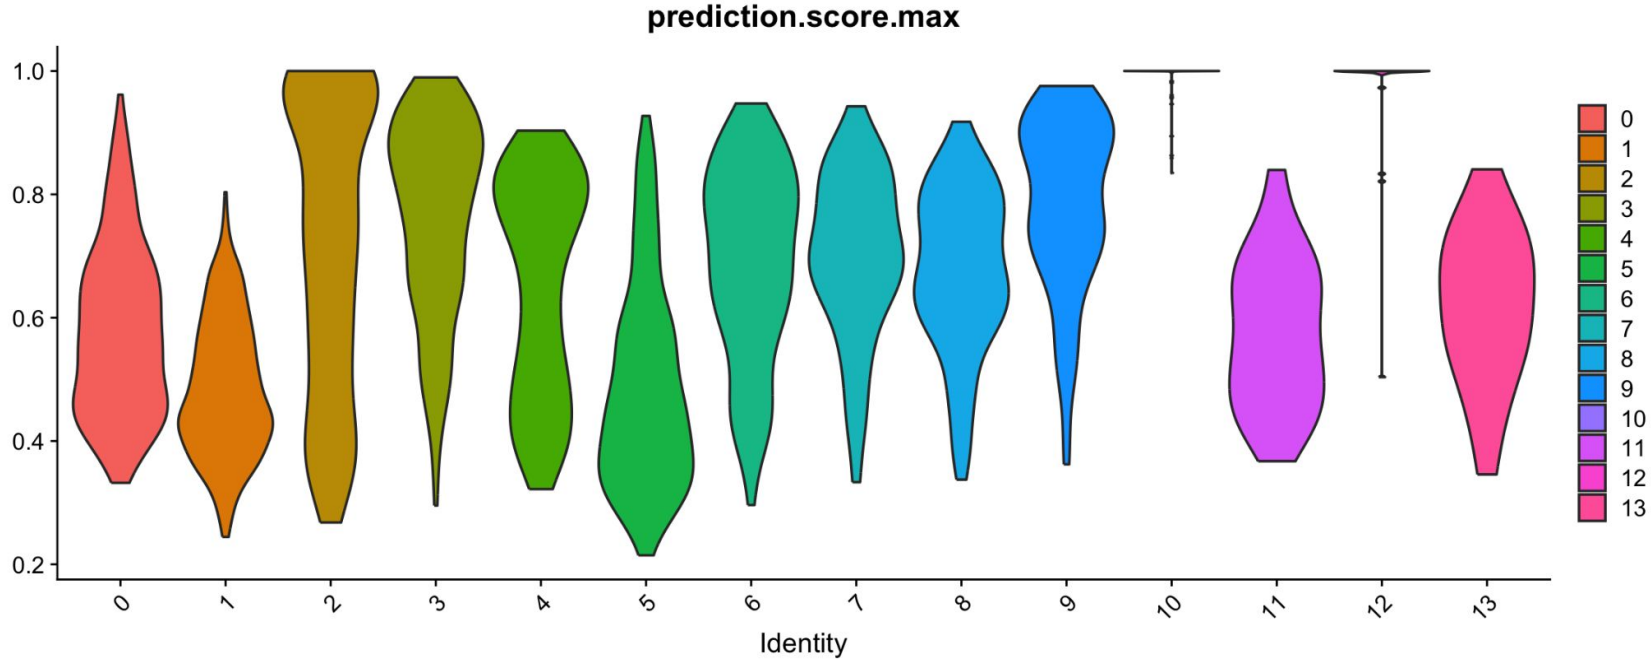
```
concordancia <- prop.table(table(Cluster = obj$seurat_clusters,
                                 Tipo_predicho = obj$cell_type), margin = 1) * 100
round(concordancia, 1)
```

```
       Tipo predicho
Cluster mEndo mEpen  mMgl mNbDA mNbL2  mNbM mNbML2 mNProg mPeric mRgl1 mRgl2  mUnk
      0   0.0   0.0   0.0   0.0   0.0  84.1   5.2    0.0    0.0   0.0   0.0  10.6
      1   0.0   0.0   0.0   0.7   0.2  74.6  12.2    0.0    0.0   0.0   0.0  12.2
      2   0.0   0.0   0.0   0.0   0.0   6.7   2.8   63.0    0.0   0.4  25.4   1.8
      3   0.0   0.0   0.0   0.0   0.0  97.3   0.8    1.2    0.0   0.0   0.0   0.8
      4   0.0   1.2   0.0   0.0   0.0   7.4   0.8   20.5    0.4   0.0  69.7   0.0
      5   0.0   0.0   0.0   9.4   1.3  76.9   3.0    0.0    0.0   0.0   0.0   9.4
      6   0.0   0.0   0.0   0.0   0.0   8.6  86.9    0.0    0.0   0.0   0.0   4.5
      7   0.0   0.0   0.0   0.0   0.0   4.7  94.6    0.0    0.0   0.0   0.0   0.7
      8   0.0   0.0   0.0   0.0   0.0   1.7  95.8    0.0    0.0   0.0   0.0   2.5
      9   0.0   0.0   0.0   0.0   0.0  99.0   0.0    0.0    0.0   0.0   0.0   1.0
      10 59.6   0.0   0.0   0.0   0.0   0.0   0.0    0.0   40.4   0.0   0.0   0.0
      11  0.0   0.0   0.0   0.0   0.0   9.1  20.5    2.3    0.0   0.0   2.3  65.9
      12  0.0   0.0 100.0   0.0   0.0   0.0   0.0    0.0    0.0   0.0   0.0   0.0
      13  5.6   0.0   0.0   0.0   0.0  16.7  77.8    0.0    0.0   0.0   0.0   0.0
```

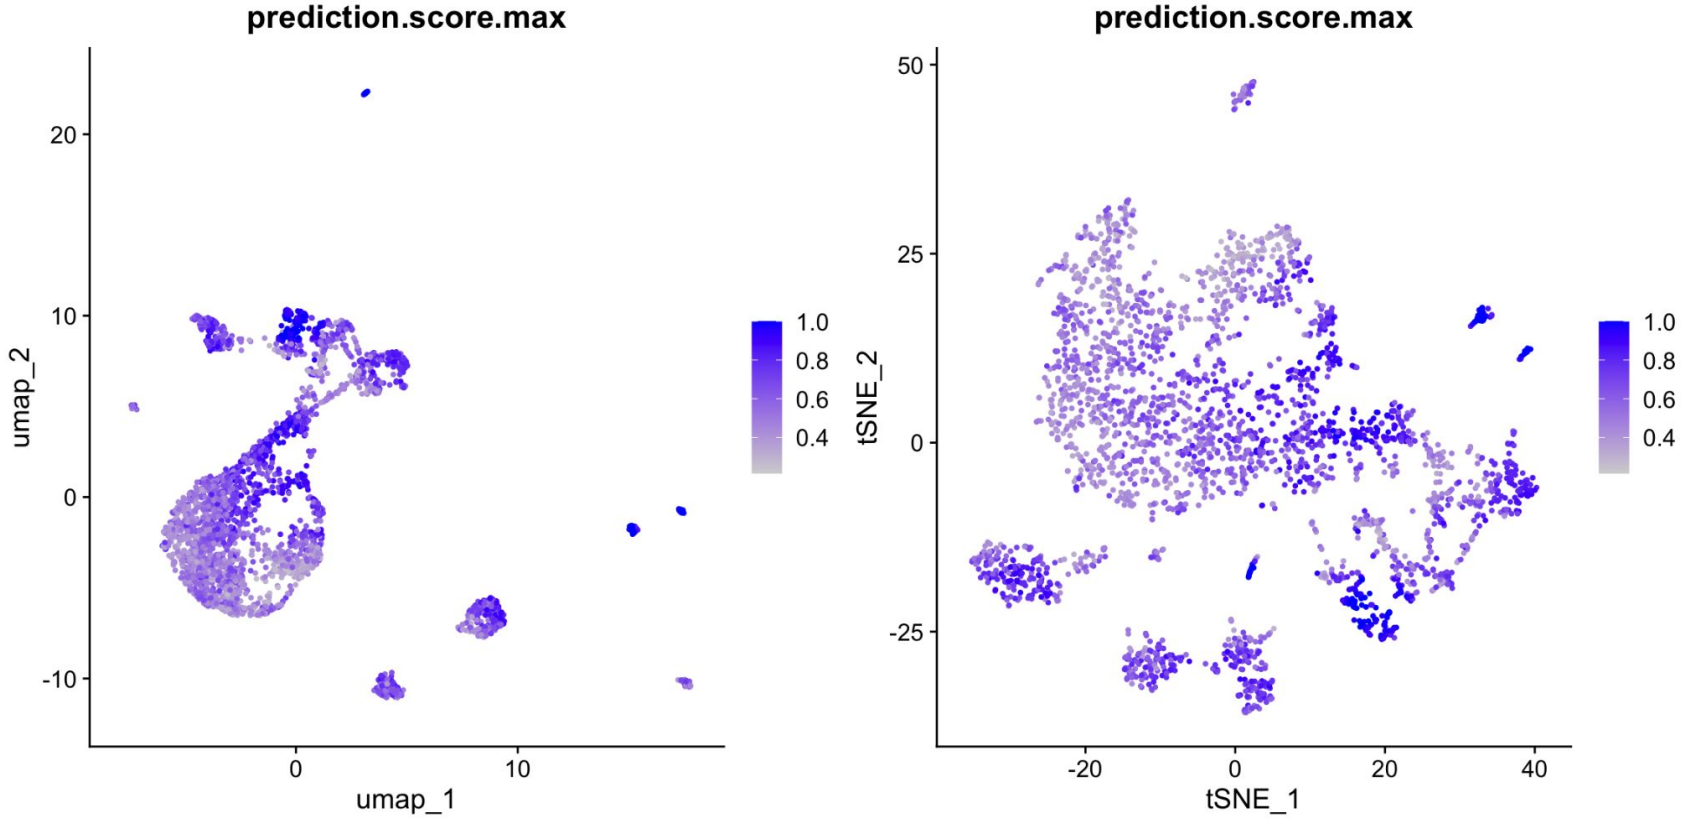
```
porcentajes <- as.data.frame(concordancia)
ggplot(porcentajes, aes(Cluster, Tipo_predicho, fill = Freq)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(low = "#377EB8", mid = "white", high = "#E41A1C",
                       midpoint = 50, limits = c(0, 100), breaks = c(0, 50, 100), name = "% células") +
  labs(x = "Cluster", y = "Tipo predicho") + theme_minimal()
```



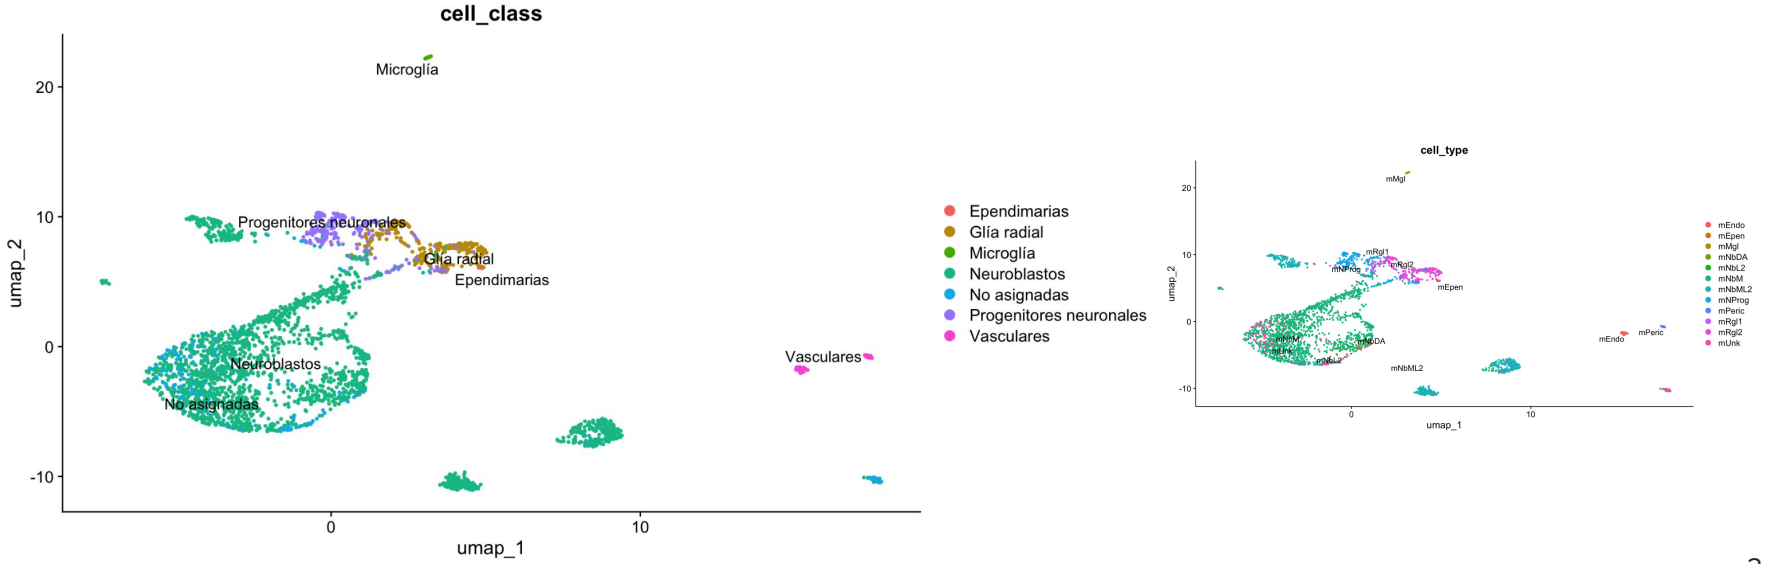
```
# El puntaje de transferencia no es una probabilidad calibrada
summary(obj$prediction.score.max)
VlnPlot(obj, features = "prediction.score.max", group.by = "seurat_clusters", pt.size = 0)
```



```
FeaturePlot(obj, features = "prediction.score.max", reduction = "umap") |
  FeaturePlot(obj, features = "prediction.score.max", reduction = "tsne")
```



```
grupos <- c(
  mNbM = "Neuroblastos", mNbML2 = "Neuroblastos",
  mNbL2 = "Neuroblastos", mNbDA = "Neuroblastos",
  mNProg = "Progenitores neuronales",
  mRgl1 = "Glía radial", mRgl2 = "Glía radial",
  mEpen = "Ependimarias", mMgl = "Microglía",
  mEndo = "Vasculares", mPeric = "Vasculares", mUnk = "No asignadas"
)
obj$cell_class <- unname(grupos[obj$cell_type])
DimPlot(obj, reduction = "umap", group.by = "cell_class", label = TRUE, repel = TRUE)
```



```
metadata <- as.data.frame(colData(sce))
# Los nombres de fila conservan Library_Barcode, igual que colnames(obj)
idx <- match(colnames(obj), rownames(metadata))
stopifnot(!anyNA(idx))
obj$Mouse <- as.character(metadata$Mouse[idx])
table(obj$Mouse)
```

```
   A    B
1521 1390
```

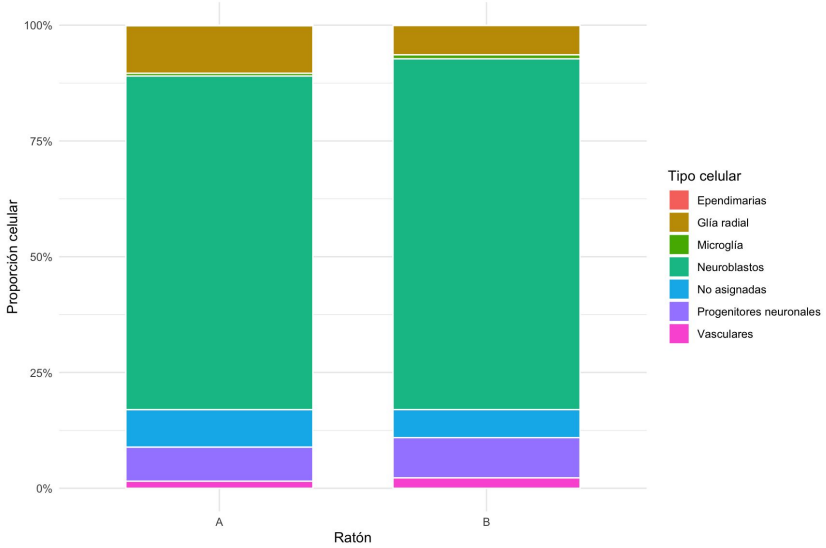
```
conteos <- table(Muestra = obj$Mouse, Tipo_celular = obj$cell_class)
conteos
```

```
       Tipo_celular
Muestra Ependimarias Glía radial Microglía Neuroblastos No asignadas Progenitores neuronales Vasculares
      A            2         156         9         1096          123                     112         23
      B            1          88        12         1053           84                     121         31
```

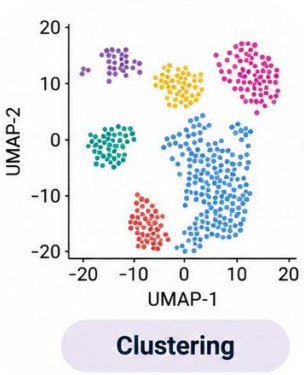
```
proporciones <- prop.table(conteos, margin = 1) * 100
round(proporciones, 1)
```

```
       Tipo_celular
Muestra Ependimarias Glía radial Microglía Neuroblastos No asignadas Progenitores neuronales Vasculares
      A          0.1        10.3       0.6         72.1          8.1                     7.4        1.5
      B          0.1         6.3       0.9         75.8          6.0                     8.7        2.2
```

```
comp <- as.data.frame(prop.table(conteos, margin = 1))
ggplot(comp, aes(Muestra, Freq, fill = Tipo_celular)) +
  geom_col(color = "white", width = 0.7) +
  scale_y_continuous(labels = scales::label_percent(accuracy = 1)) +
  labs(x = "Ratón", y = "Proporción celular", fill = "Tipo celular") + theme_minimal()
```



¿Qué podemos analizar con scRNA-seq?



1 Genes marcadores

¿Qué distingue a cada clúster?

2 Anotación celular

¿Qué tipos celulares tenemos?

3 Composición celular

¿En qué proporciones están?

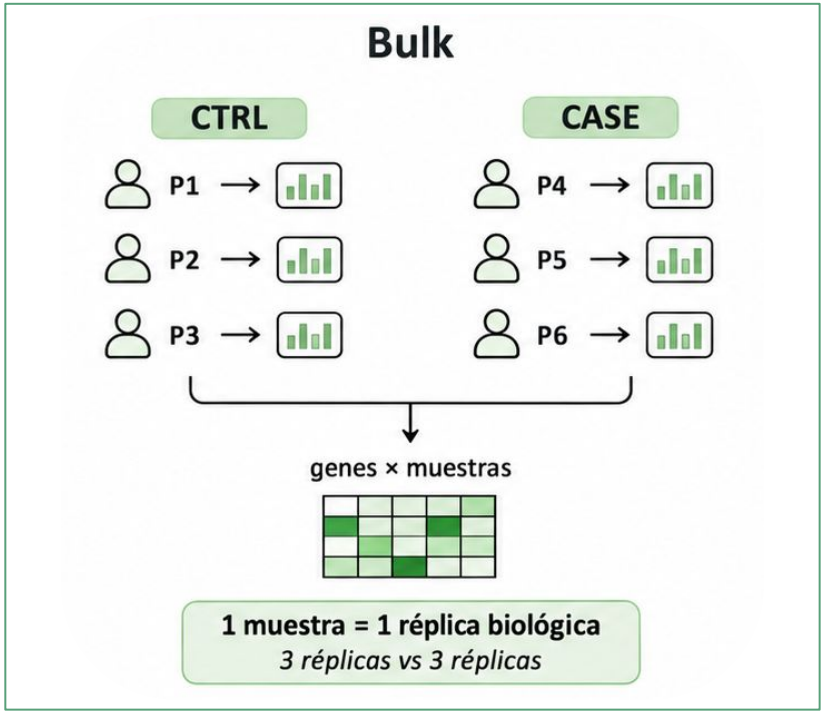
4 Pseudobulk

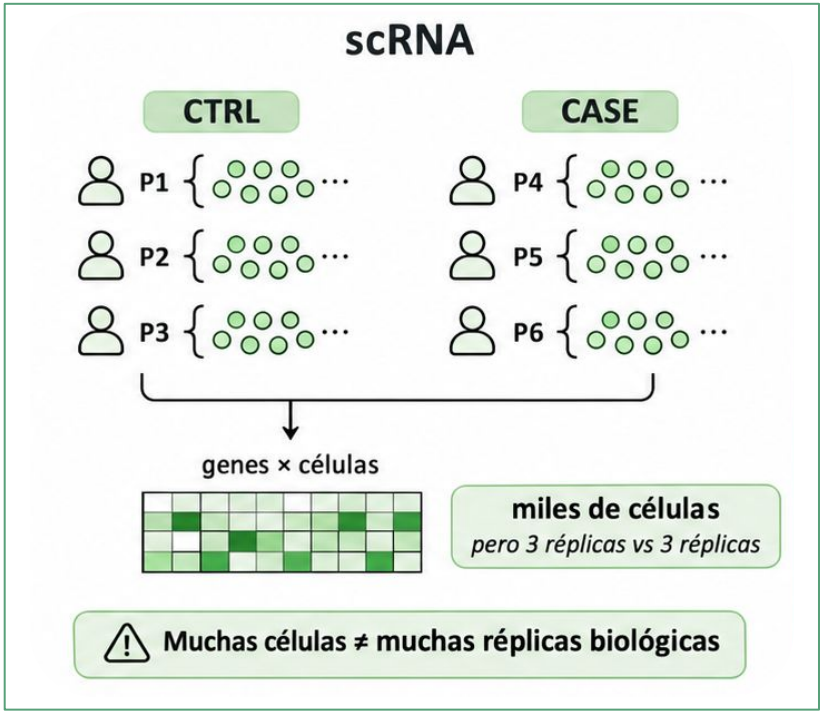
Agregación por muestra y tipo

5 Expresión diferencial

¿Qué cambia entre condiciones?

¿Cómo podemos comparar la expresión entre condiciones?

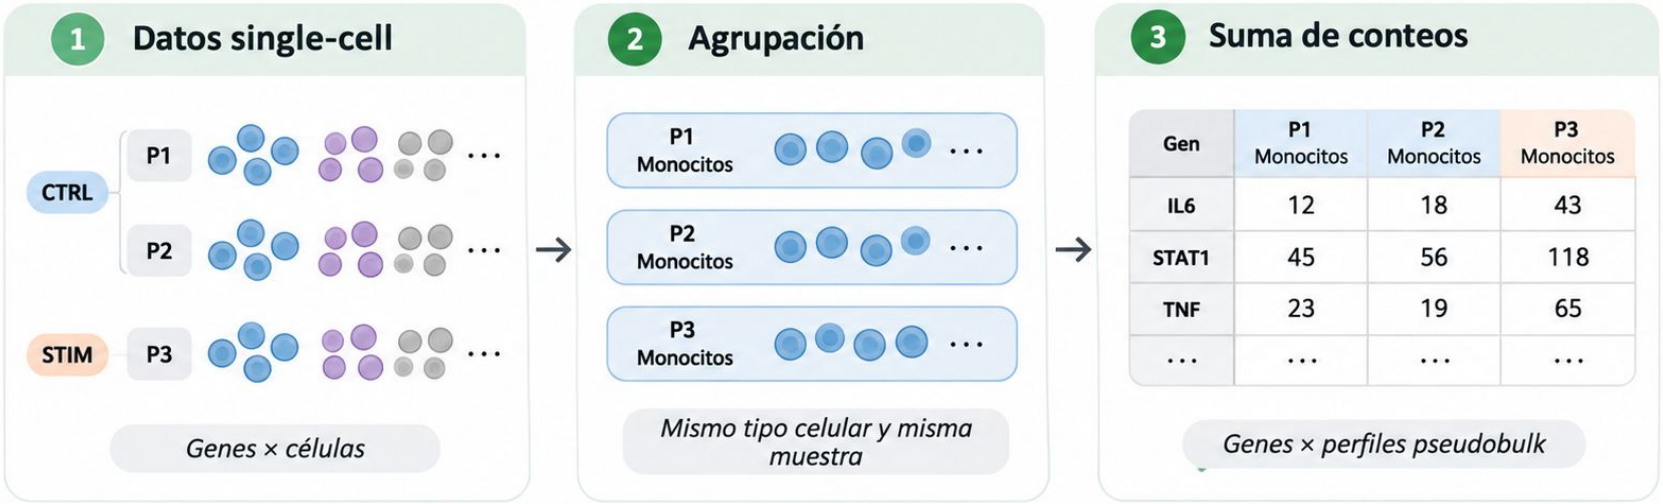




Las células no son réplicas biológicas

Solución: *pseudobulk*

Sumar los conteos de expresión de células pertenecientes al mismo tipo celular y a la muestra biológica



Gen	P1 Monocitos	P2 Monocitos	P3 Monocitos
IL6	12	18	43
STAT1	45	56	118
TNF	23	19	65
...	...	...	...

Un perfil de expresión por muestra y tipo celular

Construir una matriz pseudo-bulk con Seurat

De células a pseudobulk

3 monocitos de P1 (CTRL)

3 + 0 + 5 = 8

Single-cell
Conteos por célula

	C1	C2	C3
Gene A	3	0	5
Gene B	2	4	3

Pseudobulk
Conteos agregados

	CTRL_P1_Monocitos
Gene A	8
Gene B	9

Suma de conteos, no promedio

Seurat

```
pseudo <- AggregateExpression(
                    object = obj, assays = “RNA”,
                    group.by = c(“condition”,
“sample_id”, “cell_type),
                    return.seurat = FALSE)$RNA
```

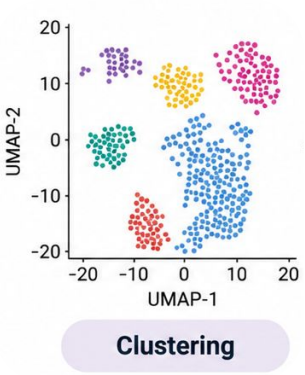
group.by

condition | sample_id | cell_type

- *Las variables dependen del diseño experimental.*
- *Si un mismo donante tiene CTRL y STIM, incluir la condición evita mezclar ambas poblaciones.*

También está la función *AverageExpression()* más utilizada para análisis como clustering o revisión de genes marcadores

¿Qué podemos analizar con scRNA-seq?



1 Genes marcadores

¿Qué distingue a cada clúster?

2 Anotación celular

¿Qué tipos celulares tenemos?

3 Composición celular

¿En qué proporciones están?

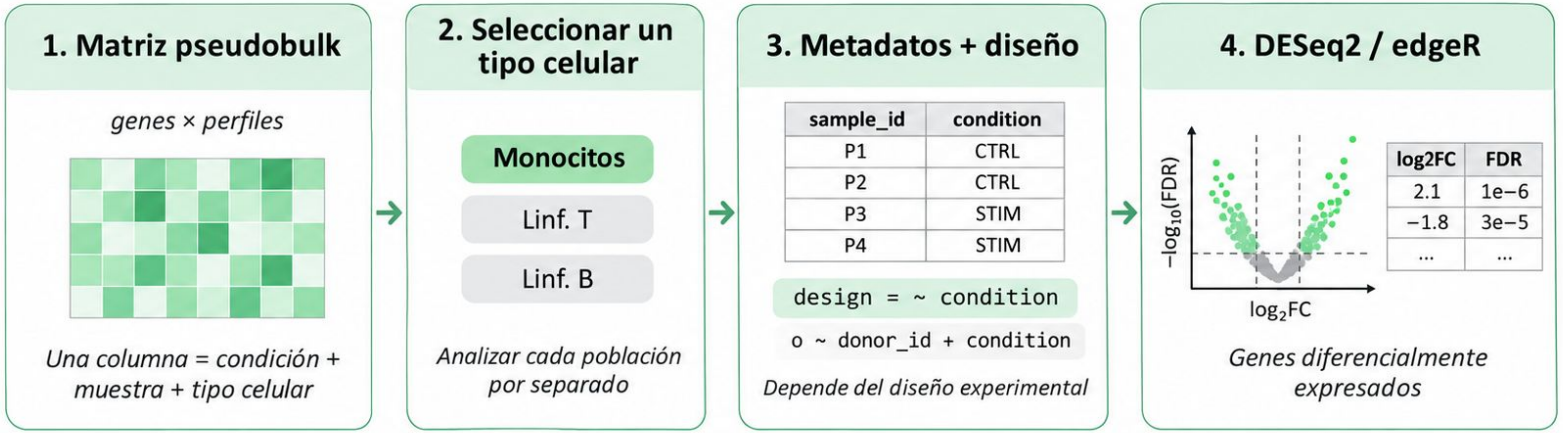
4 Pseudobulk

Agregación por muestra y tipo

5 Expresión diferencial

¿Qué cambia entre condiciones?

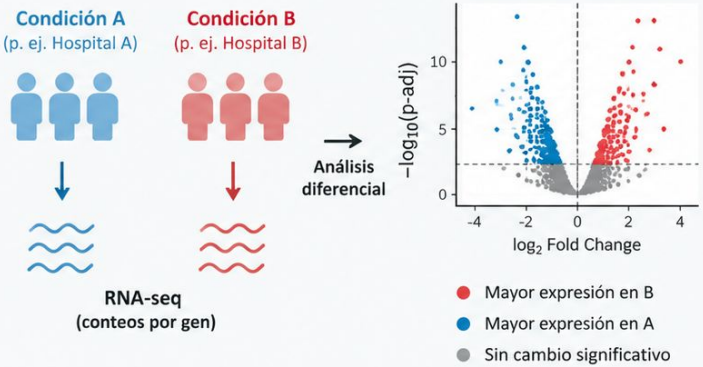
Ahora podemos hacer un análisis de expresión diferencial *bulk-like*



Análisis de expresión diferencial

¿Qué es?

Identificar genes cuya expresión cambia entre condiciones o grupos de muestras, considerando la variabilidad entre muestras.



Enriquecimiento funcional

ORA

Over-Representation Analysis

- Usa una lista de genes significativos
- Evalúa si una función o vía está sobrerrepresentada
- Útil cuando ya definimos un umbral

Práctico de pseudo-bulk

Realizar un análisis de expresión diferencial entre los monocitos CD14+ de sangre periférica de humano con casos control (CTRL) y tratados con interferón beta (STIM).

- Cargar y construir la matriz pseudo-bulk.
- ¿Cuántas células componen el dataset? ¿Cuántos pacientes en total hay y cuántos por condición?
- Seleccionar monocitos CD14+.
- Preparar los datos para el análisis: construir matriz de conteos y metadata.
- Realizar expresión diferencial con DESeq2
- Identificar y visualizar genes diferencialmente expresados (volcano plot)
- Realizar un enriquecimiento funcional con la msigdbr y la base de datos GO Biological Process

```
BiocManager::install(c("muscData", "DESeq2", "clusterProfiler"))
install.packages("msigdbr")

library(Seurat)
library(muscData)
library(SingleCellExperiment)
library(tidyverse)
library(DESeq2)
library(clusterProfiler)
library(msigdbr)
```

```
sce <- Kang18_8vs8()
obj <- CreateSeuratObject(counts = counts(sce), meta.data = as.data.frame(colData(sce)),
                          project = "Kang_IFNb", min.cells = 3, min.features = 200)

obj$donor_id <- as.character(obj$ind)
obj$condition <- toupper(as.character(obj$stim))
obj$cell_type <- as.character(obj$cell)
obj$sample_id <- paste(obj$donor_id, obj$condition, sep = "_")

cat("Células del dataset:", ncol(sce), "\nCélulas tras el filtro inicial:", ncol(obj),
    "\nPacientes en total:", n_distinct(obj$donor_id), "\n")
obj[[]] %>% distinct(donor_id, condition) %>% count(condition, name = "pacientes")
```

```
Células del dataset: 29065
Células tras el filtro inicial: 28871
Pacientes en total: 8
```

	condition	pacientes
1	CTRL	8
2	STIM	8

```
pseudo <- AggregateExpression(obj, assays = "RNA",
                              group.by = c("condition", "sample_id", "cell_type"),
                              return.seurat = FALSE)$RNA
dim(pseudo)
as.matrix(pseudo[1:10, 1:6])
```

```
[1] 16142   128
              CTRL_101-CTRL_B cells CTRL_101-CTRL_CD14+ Monocytes CTRL_101-CTRL_CD4 T cells
AL627309.1                        0                             0                         0
RP11-206L10.2                     0                             0                         0
RP11-206L10.9                     1                             0                         0
FAM87B                            0                             0                         0
LINC00115                         1                             0                         2
FAM41C                            0                             1                         0
NOC2L                            13                            11                        21
KLHL17                            0                             0                         0
PLEKHN1                           0                             1                         0
RP11-54O7.17                      0                             0                         0
              CTRL_101-CTRL_CD8 T cells CTRL_101-CTRL_Dendritic cells CTRL_101-CTRL_FCGR3A+ Monocytes
AL627309.1                            0                             0                                0
RP11-206L10.2                         0                             0                                0
RP11-206L10.9                         0                             0                                0
FAM87B                                0                             0                                0
LINC00115                             0                             1                                0
FAM41C                                0                             0                                0
NOC2L                                 9                             2                                7
KLHL17                                0                             0                                0
PLEKHN1                               0                             0                                0
RP11-54O7.17                          0                             0                                0
```

```
meta_pb <- obj[[]] %>%
  count(condition, sample_id, cell_type, donor_id, name = "n_cells")
# Seurat reemplaza los guiones bajos dentro de cada etiqueta por guiones
rownames(meta_pb) <- with(meta_pb, paste(condition, gsub("_", "-", sample_id),
                                  gsub("_", "-", cell_type), sep = "_"))
meta_pb <- meta_pb[colnames(pseudo), ]
meta_pb$condition <- factor(meta_pb$condition, levels = c("CTRL", "STIM"))
head(meta_pb)
```

	condition	sample_id	cell_type	donor_id	n_cells
CTRL_101-CTRL_B cells	CTRL	101_CTRL	B cells	101	119
CTRL_101-CTRL_CD14+ Monocytes	CTRL	101_CTRL	CD14+ Monocytes	101	246
CTRL_101-CTRL_CD4 T cells	CTRL	101_CTRL	CD4 T cells	101	340
CTRL_101-CTRL_CD8 T cells	CTRL	101_CTRL	CD8 T cells	101	99
CTRL_101-CTRL_Dendritic cells	CTRL	101_CTRL	Dendritic cells	101	24
CTRL_101-CTRL_FCGR3A+ Monocytes	CTRL	101_CTRL	FCGR3A+ Monocytes	101	96

```
# Conservar perfiles de monocitos CD14+ con al menos 20 células
coldata <- subset(meta_pb, cell_type == "CD14+ Monocytes" & n_cells >= 20,
                  select = c(donor_id, condition, sample_id, n_cells))
coldata$donor_id <- factor(coldata$donor_id)
counts_mono <- as.matrix(pseudo[, rownames(coldata), drop = FALSE])
dim(counts_mono)
table(coldata$donor_id, coldata$condition)
```

```
[1] 16142    16

      CTRL STIM
  101    1    1
  1015   1    1
  1016   1    1
  1039   1    1
  107    1    1
  1244   1    1
  1256   1    1
  1488   1    1
```

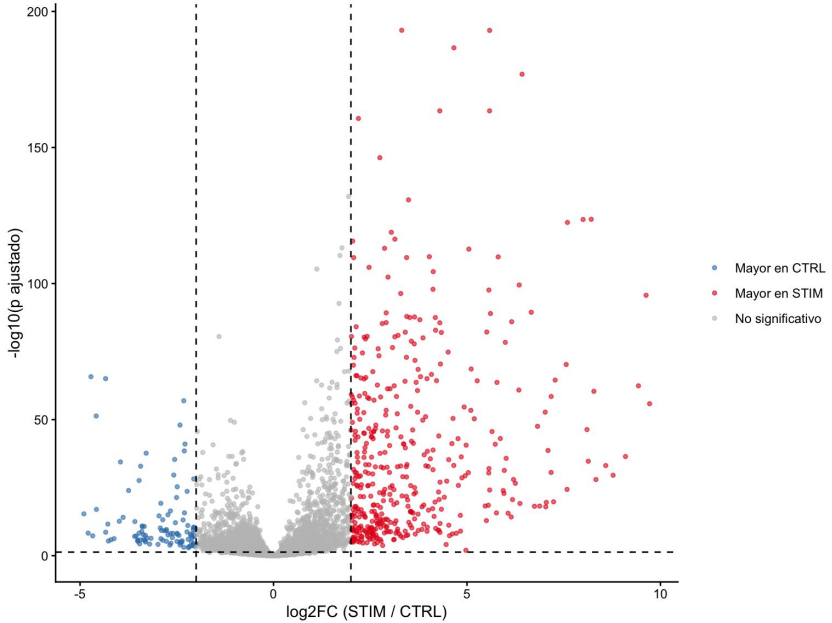
```
dds <- DESeqDataSetFromMatrix(countData = counts_mono, colData = coldata,
                              design = ~ donor_id + condition)
# Conservar genes con al menos 10 conteos en 3 o más perfiles
keep <- rowSums(counts(dds) >= 10) >= 3
dds <- dds[keep, ]
dds <- DESeq(dds)
res <- results(dds, contrast = c("condition", "STIM", "CTRL"), alpha = 0.05)
summary(res)
```

```
out of 6070 with nonzero total read count
adjusted p-value < 0.05
LFC > 0 (up)       : 1638, 27%
LFC < 0 (down)     : 1489, 25%
outliers [1]       : 0, 0%
low counts [2]     : 0, 0%
(mean count < 2)
[1] see 'cooksCutoff' argument of ?results
[2] see 'independentFiltering' argument of ?results
```

```
# Contraste STIM / CTRL: log2FC positivo indica mayor expresión en STIM
res_df <- as.data.frame(res) %>%
  rownames_to_column("gene") %>%
  filter(!is.na(padj)) %>%
  mutate(grupo = case_when(
    padj < 0.05 & log2FoldChange > 2 ~ "Mayor en STIM",
    padj < 0.05 & log2FoldChange < -2 ~ "Mayor en CTRL",
    TRUE ~ "No significativo"
  ))
table(res_df$grupo)
genes_sig <- filter(res_df, grupo != "No significativo")
```

```
Mayor en CTRL    Mayor en STIM No significativo
          106              432             5532
```

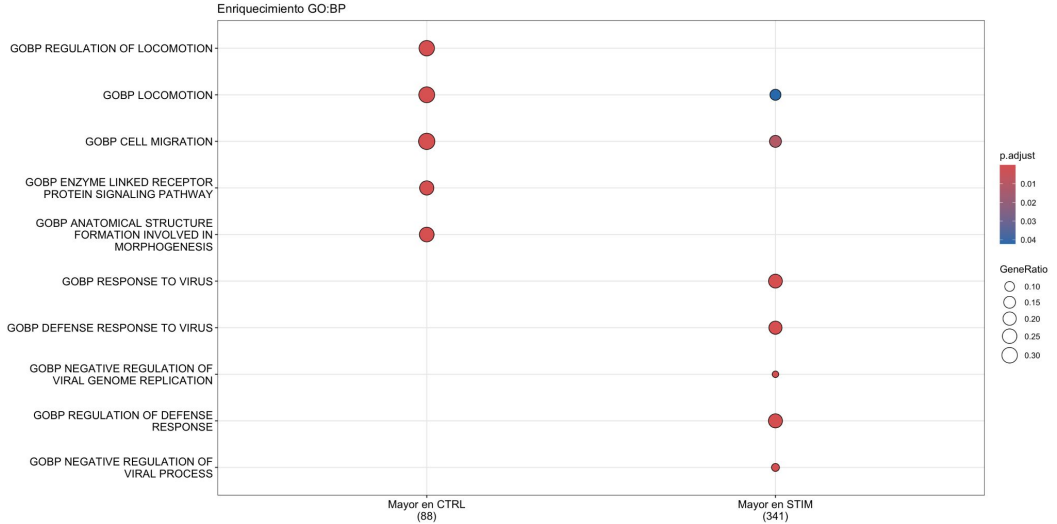
```
ggplot(res_df, aes(log2FoldChange, -log10(pmax(padj, 1e-300)), color = grupo)) +
  geom_point(alpha = 0.6, size = 1) +
  geom_vline(xintercept = c(-2, 2), linetype = "dashed") +
  geom_hline(yintercept = -log10(0.05), linetype = "dashed") +
  scale_color_manual(values = c("Mayor en CTRL" = "#377EB8",
                                "Mayor en STIM" = "#E41A1C",
                                "No significativo" = "grey75")) +
  labs(x = "log2FC (STIM / CTRL)", y = "-log10(p ajustado)", color = NULL) +
  theme_classic()
```



```
go_bp <- msigdbr(species = "Homo sapiens", collection = "C5", subcollection = "GO:BP") %>%
  dplyr::select(gs_name, gene_symbol) %>%
  distinct()

genes <- split(genes_sig$gene, genes_sig$grupo)
enriq <- compareCluster(
  geneClusters = genes,
  fun = "enricher",
  TERM2GENE = go_bp,
  universe = res_df$gene,
  pAdjustMethod = "BH",
  pvalueCutoff = 0.05)

enrichplot::dotplot(enriq, showCategory = 5) + labs(x = NULL, title = "Enriquecimiento GO:BP")
```



FACULTAD DE MEDICINA
UNIVERSIDAD DE CHILE

Magíster en Informática Médica

Single-cell RNA-seq II

Noemí Gómez
07 de noviembre, 2026

noemi.gomez@postgrado.uoh.cl